

Resumo da Arquitetura da Solução

Documento de visão rápida do **SRAG Data Health Agent Chatbot Monitor**: o que o sistema faz (síntese do README), como a arquitetura se organiza e como o **agente orquestrador** funciona.

Para detalhes: [README.md](#), [arquitetura_solucão_srag.md](#) e [agente_orquestrador.md](#).

Em uma frase

Dados públicos de SRAG (OpenDataSUS) → pipeline ETL → DuckDB → API FastAPI de métricas → dashboard Shiny com **chatbot** e **relatório por IA** (PDF), orquestrado por LangGraph com tools, Tavily e auditoria.

Acesso

Serviço	URL
Dashboard	http://localhost:8080
API	http://localhost:8000
Swagger	http://localhost:8000/docs

O que o sistema entrega

Bloco	Função
Pipeline	Download dos CSVs OpenDataSUS + ETL → <code>data/srag.duckdb(srag_notificacoes)</code>
Métricas	Quatro indicadores + séries diária/mensal por UF ou <code>BRASIL</code>
Dashboard	Chatbot + seção Relatório gerado por IA + Baixar PDF
Orquestrador	LangGraph ReAct: escolhe tools (métricas, séries, gráficos, notícias, relatório)
Auditoria	Cada execução em <code>agent_audit_log</code> (consultável via API)


Fluxo de valor (resumo do README)

- 1. Baixa e prepara os CSVs SRAG (2019–2026).
- 2. Persiste no DuckDB e expõe métricas pela API.
- 3. O analista conversa no chatbot ou pede um relatório (UF / Brasil).
- 4. O orquestrador consulta dados oficiais e notícias, sintetiza o texto e devolve gráficos (ChartSpec).
- 5. O dashboard mostra o relatório completo; o PDF é gerado sob demanda (ReportLab), sem nova chamada à LLM.

Arquitetura da solução

Padrão MVC na API:

Camada	Papel
Views	Rotas HTTP (dataset, metrics, agents)
Controlllers	Orquestração HTTP e erros
Services	ETL, métricas, LangGraph, PDF, auditoria
Models	Schemas Pydantic



Stack principal

FastAPI · DuckDB · Shiny · Plotly · LangGraph/LangChain · OpenAI · Tavily · ReportLab · Docker

Endpoints que mais importam

Endpoint	Uso
POST /datasets/pipeline	Prepara os dados
GET /metrics/{estado}	Métricas oficiais
POST /agents/chat	Chatbot (fluxo principal do dashboard)
POST /agents/report	Relatório one-shot via API
POST /agents/report/pdf	Exporta PDF do relatório já gerado
GET /agents/audit	Governança das execuções

Como o agente orquestrador funciona

Classe central: `LangGraphOrchestratorAgent`
(`app/services/langgraph_orchestrator_agent.py`).

Ideia central

O orquestrador **não** segue um roteiro fixo de ferramentas. Usa **ReAct** (`create_react_agent`): a LLM decide, a cada passo, se responde ou chama uma tool — e qual.


Características:

- Memória multi-turno (`MemorySaver` + `session_id`)
- Tools de métricas consomem a **API do projeto** (não o DuckDB direto)
- Relatório completo só em **pedido explícito** (`gerar_relatorio_executivo`)
- Temperatura padrão da LLM: 0

Tools

Tool	Quando costuma ser usada
<code>consultar_metricas_srag</code>	Indicadores oficiais (4 métricas)
<code>consultar_serie_temporal</code>	Tendência diária ou mensal
<code>gerar_especificacao_grafico</code>	Monta <code>ChartSpec</code> para Plotly/PDF
<code>buscar_noticias_srag</code>	Contexto de mídia (Tavily + guardrails)
<code>gerar_relatorio_executivo</code>	Pedido explícito de relatório / resumo executivo

Fluxo no chatbot



1. Garante que o pipeline de dados está pronto.
2. Loop ReAct: escolhe e executa tools.
3. Responde no chat (escopo e período quando usa métricas).
4. Se pediu relatório: monta `report` e devolve para a UI (texto longo **não** vai na bolha de resposta).
5. Grava auditoria e retorna `audit_id`.

O que entra no relatório

Parte	Origem
Narrativa em prosa	OpenAI
Tabela ## Quatro métricas principais	API do próprio projeto
Seção ## Notícias encontradas (com links)	Tavily
<code>charts</code> (diário/mensal)	Classe ChartSpecService (próprio projeto)

Limite total do `resumo_executivo`: **5000** caracteres.

PDF

POST `/agents/report/pdf` recebe `estado` + `resumo_executivo` + `charts` e gera o PDF com ReportLab (**sem** nova chamada à LLM). No dashboard, a bolha **Baixar PDF** no chat usa esse endpoint.

Guardrails (resumo)

- Escopo: SRAG / saúde respiratória no Brasil
 - Números só via tools oficiais (não inventa)
 - Relatório completo só sob pedido explícito
 - Notícias filtradas (domínios e termos)
-

Experiência no dashboard

1. Perguntas pontuais → resposta nas bolhas do chat.
 2. “Gere o relatório de PE/RJ/Brasil...” → reply curto no chat + texto/gráficos em **Relatório gerado por IA**.
 3. Bolha **Baixar PDF** aparece no log do chat (atualiza se um novo relatório for gerado).
 4. **Nova conversa** reinicia a sessão e limpa o relatório atual.
-

Documentação complementar

Documento	Conteúdo
README.md	Visão geral, execução Docker, endpoints
docs/arquitetura_solucão_srag.md	Arquitetura conceitual detalhada
docs/agente_orquestrador.md	Tools, guardrails, PDF, auditoria, testes
docs/etl_pipeline.md	Download e ETL
docs/metricas_srag.md	Cálculo das métricas